

서울시 다릉이 자전거 이용 여측 모델

4조 이승준 이한재 정노아

CONTENTS



Contents 01
데이터 및 변수 소개



Contents 02
데이터 전처리



Contents 03
모델링



Contents 04
평가 및 결론

01 데이터 및 변수 소개

데이터 소개

Train data

Id	Hour	Hour_bef_temperature	Hour_bef_precipitation	Hour_bef_windspeed	Hour_bef_humidity	Hour_bef_visibility	...	count
3	20	16.3	1	1.5	89	576	...	49
6	13	20.1	0	1.4	48	916	...	159
7	6	13.9	0	0.7	79	1382	...	26
8	23	8.1	0	2.7	54	946	...	57
9	18	29.5	0	4.8	7	2000	...	431
...	...	...	...	...	...	...	...	...

Obs : 1459 개
변수 : 11개

01 데이터 및 변수 소개

데이터 소개

Test data

Id	Hour	Hour_bef_temperature	Hour_bef_precipitation	Hour_bef_windspeed	Hour_bef_humidity	Hour_bef_visibility	...
3	20	16.3	1	1.5	89	576	...
6	13	20.1	0	1.4	48	916	...
7	6	13.9	0	0.7	79	1382	...
8	23	8.1	0	2.7	54	946	...
9	18	29.5	0	4.8	7	2000	...
...	...	...	...	...	...	...	...

Obs : 715 개
변수 : 10개

01 데이터 및 변수 소개

변수 소개

변수 소개

Id : 고유 id

Hour : 시간

Hour_bef_temperature : 1시간 전 기온

Hour_bef_precipitation : 1시간 전 비가 오지 않았으면 0, 비가 왔으면 1

Hour_bef_windspeed : 1시간 전 평균 풍속

Hour_bef_humidity : 1시간 전 습도

Hour_bef_visibility : 1시간 전 가시성

Hour_bef_ozone : 1시간 전 오존



Hour_bef_pm10 : 1시간 전 미세먼지(pm10)

Hour_bef_pm2.5 : 1시간 전 미세먼지(pm2.5)

Count : 따릉이 대여 수 (목적변수)

01 데이터 및 변수 소개



변수 소개(hour_bef_temperature)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
3.1	12.8	16.6	16.72	20.1	30	2

01 데이터 및 변수 소개



변수 소개(hour_bef_windspeed)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
0.0	1.4	2.3	2.479	3.4	8.0	9

01 데이터 및 변수 소개



변수 소개(hour_bef_humidity)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
7.0	36.0	51.0	52.23	69.0	99	2

01 데이터 및 변수 소개



변수 소개(hour_bef_visibility)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
78	879	1577	1405	1994	2000	2

01 데이터 및 변수 소개



변수 소개(hour_bef_ozone)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
0.003	0.0255	0.039	0.03915	0.052	0.125	76

01 데이터 및 변수 소개



변수 소개(hour_bef_pm10)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
9.0	36.0	51.0	57.17	69.0	269.0	90

01 데이터 및 변수 소개


변수 소개(hour_bef_pm2.5)



Min	1 st qu.	Median	Mean	3 rd qu.	Max	Na's
8.0	20.0	26.0	30.33	37.0	90.0	117

01 데이터 및 변수 소개

결측값(NA)



변수별 결측값(NA) 개수

Temperature : 2

Precipitation : 2

Windspeed : 9

Humidity : 2

Visibility : 2


Ozone : 76

Pm10 : 90

Pm2.5 : 117

02 데이터 전처리 이상치



✓ 풍속(hour_bef_windspeed), 오존(hour_bef_ozone)의 outlier



관측될 수 있는 값이라 판단 -> 제거하지 않음

02 데이터 전처리 이상치

✓ 미세먼지(hour_bef_pm10, hour_bef_pm2.5)의 outlier



* 매우 나쁨 등급

pm10 : 151 이상
pm2.5 : 76 이상

2017년 4,5월 자료. 관측될 수 있는 값이라 판단 -> 제거하지 않음

02 데이터 전처리 결측치

train, test dataset 결측치 개수

train dataset

id	0
hour	0
hour_bef_temperature	2
hour_bef_precipitation	2
hour_bef_windspeed	9
hour_bef_humidity	2
hour_bef_visibility	2
hour_bef_ozone	76
hour_bef_pm10	90
hour_bef_pm2.5	117
count	0

test dataset

id	0
hour	0
hour_bef_temperature	1
hour_bef_precipitation	1
hour_bef_windspeed	1
hour_bef_humidity	1
hour_bef_visibility	1
hour_bef_ozone	35
hour_bef_pm10	37
hour_bef_pm2.5	36

02 데이터 전처리 결측치

✓ train dataset

	id	hour	hour_bef_temperature	hour_bef_precipitation	hour_bef_windspeed	hour_bef_humidity	hour_bef_visibility	hour_bef_ozone	hour_bef_pm10	hour_bef_pm2.5	count
934	1420	0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	39.0
1035	1553	18	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	1.0

id hour count 외 모두 결측치인 행 -> 삭제

02 데이터 전처리 결측치



✓ test dataset

id	hour	hour_bef_temperature	hour_bef_precipitation	hour_bef_windspeed	hour_bef_humidity	hour_bef_visibility	hour_bef_ozone	hour_bef_pm10	hour_bef_pm2.5
653	1943	19	NaN	NaN	NaN	NaN	NaN	NaN	NaN

id hour 제외 모두 결측치인 obs 존재
-> 19시일 때의 중위수값들로 결측치 대체

02 데이터 전처리 결측치

✓ 풍속(hour_bef_windspeed) 결측치



	count	mean	std	min	25%	50%	75%	max
hour								
0	59.0	0.033763	0.016296	0.003	0.02250	0.0350	0.04250	0.074
1	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	61.0	0.030492	0.016567	0.003	0.01800	0.0310	0.03900	0.083
3	61.0	0.031213	0.017270	0.003	0.01800	0.0340	0.04100	0.082

1시 데이터 오존(hour_bef_ozone) 모두 NA


1시인 풍속 결측

-> 1시일 때 풍속의 중위수로 대체


풍속(hour_bef_windspeed)와 상관계수가 높은
오존(hour_bef_ozone)을 이용해 결측치 대체 * $r=0.517731$

02 데이터 전처리 결측치

✓ 풍속(hour_bef_windspeed) 결측치



풍속(hour_bef_windspeed)와 상관계수가 높은
오존(hour_bef_ozone)을 이용해 결측치 대체 * $r=0.517731$



hour_bef_ozone	hour_bef_windspeed
0.003	1.7
0.004	1.0
0.005	1.0
0.006	0.9
0.007	1.3
...	...
0.099	3.8
0.100	3.2
0.106	4.1
0.112	3.9
0.125	4.4


1시가 아닌 풍속 결측

-> 오존별 풍속의 중위수로 대체

(오존별 풍속으로 그룹화 했을 시 NA 없음)

02 데이터 전처리 결측치

✓ 오존(hour_bef_ozone) 결측치




오존(hour_bef_ozone)과 상관계수가 높은
온도(hour_bef_temperature)을 이용해 결측치 대체 * $r=0.541228$

hour_bef_temperature
min 3.1 / max 30.0 / count 1457


1°C 씩 구간을 나눈 후,
구간별 오존의 중위수값으로 대체
ex. hour_bef_temperature = 21.7인 경우
온도가 [21,22) 인 구간의 오존 중위수로 NA 대체

02 데이터 전처리 결측치

✓ 미세먼지(hour_bef_pm10, hour_bef_pm2.5) 결측치



$r=-0.403277$




$r=-0.644989$

시정(hour_bef_visibility)을 이용해 결측치 대체

02 데이터 전처리 결측치

✓ 미세먼지(hour_bef_pm10, hour_bef_pm2.5) 결측치




hour_bef_visibility
min 78.0 / max 2000.0 / count 1457

100 씩 구간을 나눈 후,
구간별 미세먼지의 중위수로 대체
ex. hour_bef_visibility = 1071.0인 경우
시정미 [1000,1100) 인 구간의 미세먼지 중위수로 NA 대체


03 모델링 모델 소개

Contents 03. Random Forest

- 앙상블 기법의 대표 모델
- 결정트리와 bagging 결합 모델
- 과적합을 방지하고 안정성 높음
- 스케일에 구애받지 않음
- 다중공선성 영향이 적음



03 모델링 모델 소개



GridSearch

관심있는 매개변수들로 가능한 모든
조합을 시도하여 최적의 매개변수를
찾는 방법

03 모델링 최종 모델

400

@n_estimators

결정트리의 갯수를 지정

Default = 10

2

@min_samples_split

노드를 분할하기 위한
최소한의 샘플 데이터수

과적합을 제어하는데 사용

작게 설정할 수록 분할 노드가
많아져 과적합 가능성 증가

Default = 2

15

@max_depth

트리의 최대 깊이

완벽하게 클래스 값이 결정될
때 까지 분할
또는 데이터 개수가
min_samples_split보다
작아질 때까지 분할

깊어지면 과적합 가능성
default = None

-1

@n_jobs

cpu 개수

n_jobs=-1 하면 cpu 모두

최종 모델

RandomForestRegressor(n_estimators=400, n_jobs = -1, min_samples_split=2,max_depth=15).

최종 제출 결과

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

RMSE(평균제곱근 오차) = 32.247...

590091

1003data.csv
edit

2021-10-05
17:40:47


32.2472004719




04 평가 및 결론 변수 중요도

```
feature_importance = pd.Series(index=features, data=model.feature_importances_).sort_values(ascending=False)
feature_importance.plot(kind='bar', figsize=(24, 5), title="피쳐 중요도", rot=0)
plt.xticks(rotation=45)
plt.show()
```


〈변수중요도〉



04 평가 및 결론 변수 중요도





출퇴근 시간 : 오전 8시, 오후 6시
저 시간대에 사용량이 몰릴 것으로 예상



주로 기온이 올라갈수록 사용량 몰림
오후 시간대에 사용량이 많기에 이런 그래프가 그려짐


04 평가 및 결론 변수 중요도




(hour, count) plot과 (hour, temperature) plot의 모양이 비슷하다.

주로 온도가 높은 오후에 사용량이 높기 때문에
온도가 높을수록 사용량이 높게 보인다.

04 평가 및 결론 변수 중요도



출퇴근 시간 : 오전 8시, 오후 6시
저 시간대에 사용량이 몰릴 것으로 예상



주로 기온이 올라갈수록 사용량 몰림
오후 시간대에 사용량이 많기에 이런 그래프가 그려짐

결론 : 원활한 사용을 위해 출퇴근 시간에 역 근처 반납자전거를
사용량 많은 대여지점에 옮겨두는게 좋을 것 같다.

Thank you!

감사합니다.

끝까지 함께해 주셔서 감사합니다.

