

비어플 여름 프로젝트 공모전 C조

기상 정보를 활용한 대형 산불 위험 환경 분석

이윤서 정노아




목차

1. 분석목적 및 데이터 소개
2. EDA 및 전처리
3. 비지도 학습
4. 모델링
5. 결론

1. 분석목적 및 데이터 소개


UNEP 2022년 보고서




대형 산불 발생 건수

2030년까지 최대 14%, 2050년까지 최대 30% 증가

1. 분석목적 및 데이터 소개



1. 분석목적 및 데이터 소개



기상 정보를 활용

- 산불 대형화 가능성이 높은 기상조건 파악
- 드론 활용 등 산불 감시 및 빠른 초기 대응

1. 분석목적 및 데이터 소개

2012~2021년 강원도 산불 발생 자료와 기상 자료

자료명	제공기관	기간
예년산불피해대장	산림청	2012~2021
기상관측통계(지상,시간)	MDIS 기상청	2014~2020
종관기상관측(ASOS)	기상청 기상자료개방포털	2012,2013,2021
방재기상관측(AWS)	기상청 기상자료개방포털	2012~2021

1. 분석목적 및 데이터 소개

2012~2021년 강원도 기상 자료

2012 2013	종관기상관측	방재 기상 관측
2014 ~ 2020	기상관측통계	
2021	종관기상관측	

제공지점 없는 7개 시/군/구
고성 삼척 양구 양양 평창 화천 횡성

1. 분석목적 및 데이터 소개

선별한 변수 소개

2012~2021년 강원도 기상 자료

	변수명	변수설명		변수명	변수설명
1	연도	관측 연도	9	풍향	풍향
2	월	관측 월	10	습도	습도(%)
3	일	관측 일	11	증기압	증기압(hPa)
4	시	관측 시	12	이슬점온도	이슬점온도(°C)
5	지점명	시군구	13	해면기압	해면기압(hPa)
6	기온	기온(°C)	14	현지기압	현지기압(hPa)
7	강수량	강수량(mm)	15	일조	일조(hr)
8	풍속	풍속(m/s)	16	지면온도	지면온도(°C)

1. 분석목적 및 데이터 소개

선별한 변수 소개

2012~2021년 산림청 산불 자료

	변수명	변수설명
1	발생일시_년	발생 연도
2	발생일시_월	발생 월
3	발생일시_일	발생 일
4	발생일시_시간	발생 시간
5	진화종료시간_년	진화종료 년
6	진화종료시간_월	진화종료 월
7	진화종료시간_일	진화 종료 일
8	진화종료시간_시간	진화 종료 시간
9	발생장소_시군구	발생장소 (시군구)
10	발생원인_구분	건(건축물화재), 기(기타), 쓰(쓰레기소각), 입(입산자실화), 담(담뱃불실화)
11	피해면적_합계	피해면적 합계 (ha)

2. EDA 및 전처리

산불 데이터 오류값


발생일 시_년	발생 일시 _월	발생 일시 _일	발생일 시_시간	진화종 료시간 _년	진화 종료 시간 _월	진화 종료 시간 _일	진화종 료시간 _시간	발생 장소 _시 _군구	발생장 소_읍 면	발생 장소_ 동리	발생 원인_ 구분	발생원인_ 세부원인	발생 원인_ 기 타	피해 면적_ 합계
2021	6	7	15:13	2021	6	7	17:00	강릉	주문진	향호	쓰	쓰레기소각	NaN	0.01
2021	6	7	15:13	2021	6	7	16:00	강릉	주문진	향호	기	기타 (직접입력)	원인 미상	0.01

중복 행으로 판단


→ 아래 행 제거

2. EDA 및 전처리


산불 데이터



춘천, 홍천 지역일수록



3,4,5월(봄)일수록



‘기’와 ‘입’일수록

→ 산불 횟수 ↑

2. EDA 및 전처리


기상 데이터 결측치

	변수명	결측치 수		변수명	결측치 수
1	연도	0	9	풍향	2981
2	월	0	10	습도	2281
3	일	0	11	증기압	613368
4	시	0	12	이슬점온도	613649
5	지점명	0	13	해면기압	607077
6	기온	362	14	현지기압	606440
7	강수량	1080663	15	일조	662031
8	풍속	1651	16	지면온도	614516

- 해면기압과 현지기압 0이하의 오류값 존재 : 결측치로 처리
- 근처값으로 대체

2. EDA 및 전처리

최종 데이터 생성



기준 : '연도', '월', '시', '발생장소_시군구'

2. EDA 및 전처리

파생변수 생성

< 진화 소요 시간 변수 >

‘발생일시_년’, ‘발생일시_월’, ‘발생일시_일’,
‘발생일시_시간’, ‘진화종료시간_년’, ‘진화종료시간_월’,
‘진화종료시간_일’, ‘진화종료시간_시간’

datetime 형식 가진
‘발생일시’, ‘진화종료일시’ 변수 임의로 생성
‘진화종료일시’ - ‘발생일시’ = ‘진화시간’



< 대형 산불 변수 >

‘대형산불’

‘피해면적_합계’ $\geq 30\text{ha}$: 1

‘피해면적_합계’ $< 30\text{ha}$: 0

이진형 변수 생성



2. EDA 및 전처리

One hot encoding


범주형 변수 : 발생장소_시군구



'발생장소_시군구_강릉', '발생장소_시군구_고성', '발생장소_시군구_동해', '발생장소_시군구_삼척',
'발생장소_시군구_속초', '발생장소_시군구_양구', '발생장소_시군구_양양', '발생장소_시군구_영월',
'발생장소_시군구_원주', '발생장소_시군구_인제', '발생장소_시군구_정선', '발생장소_시군구_철원',
'발생장소_시군구_춘천', '발생장소_시군구_태백', '발생장소_시군구_평창', '발생장소_시군구_홍천',
'발생장소_시군구_화천', '발생장소_시군구_횡성'

2. EDA 및 전처리

정규화



시각화를 통해 정규성 확인
로그 or 루트 변환을 통해 정규성 만족



2. EDA 및 전처리

표준화

모든 수치형 변수 단위 다름

→ standard scaler 이용 표준화

평균 0, 분산 1




3. 비지도 학습

주성분 분석

기상 관련 연속형 변수들 상관관계

기온	1	0.0082	0.1	0.06	-0.15	0.46	-0.39	-0.27	0.063	0.29
강수량	0.0082	1	0.057	0.052	-0.097	0.21	-0.24	0.18	0.36	0.35
풍속	0.1	0.057	1	0.24	-0.33	-0.067	-0.18	-0.14	0.046	0.048
풍향	0.06	0.052	0.24	1	-0.28	-0.017	-0.025	0.059	0.14	0.088
습도	-0.15	-0.097	-0.33	-0.28	1	0.25	0.061	-8e-06	-0.29	-0.21
아슬겉온도	0.46	0.21	-0.067	-0.017	0.25	1	-0.63	0.084	0.43	0.76
현지기압	-0.39	-0.24	-0.18	-0.025	0.061	-0.63	1	0.21	-0.47	-0.68
해면기압	-0.27	0.18	-0.14	0.059	-8e-06	0.084	0.21	1	0.34	0.25
일조	0.063	0.36	0.046	0.14	-0.29	0.43	-0.47	0.34	1	0.8
자면온도	0.29	0.35	0.048	0.088	-0.21	0.76	-0.68	0.25	0.8	1
기온		강수량	풍속	풍향	습도	아슬겉온도	현지기압	해면기압	일조	자면온도

상관행렬 고유값 분해



→ 4개의 주성분 (설명력 74%)

3. 비지도 학습

주성분 분석

10개 변수 → 4개 변수

기온	0.24	0.0041	0.5	-0.25
강수량	0.25	-0.054	-0.26	0.62
풍속	0.079	-0.52	0.21	0.27
풍향	0.085	-0.47	-0.045	-0.58
습도	-0.12	0.61	0.034	-0.045
이슬점온도	0.44	0.34	0.13	-0.2
현지기압	-0.44	-0.059	-0.28	-0.17
해면기압	0.086	0.047	-0.65	-0.27
일조	0.44	-0.087	-0.31	-0.0052
지면온도	0.52	0.046	-0.11	-0.064
	pc1	pc2	pc3	pc4

PC1 = $0.44 \times \text{이슬점온도} - 0.44 \times \text{현지기압} + 0.44 \times \text{일조} + 0.52 \times \text{지면온도}$

→ 태양열을 많이 받는 날씨

PC2 = $-0.52 \times \text{풍속} - 0.47 \times \text{풍향} + 0.61 \times \text{습도} + 0.34 \times \text{이슬점온도}$

→ 바람이 불지 않는 습한 날씨

PC3 = $0.5 \times \text{기온} - 0.65 \times \text{해면기압} - 0.31 \times \text{일조}$

→ 온대 저기압


PC4 = $0.62 \times \text{강수량} - 0.58 \times \text{풍향}$

→ 강수량이 많은 날씨


3. 비지도 학습

군집 분석

PC1 - PC2 K-means



계절별 군집




봄 : cluster 0 & 1 & 2 비율 거의 비슷

3. 비지도 학습

군집 분석

PC1 - PC3 DBSCAN



DBSCAN - 밀도 기반 클러스터링

- $\text{eps} = 0.7$
- $\text{min_samples} = 15$

반경 0.7 내 최소 15개의 점이 있으면 core point


-1 : 노이즈

0 : 일조량이 적고 저기압인 경우

1 : 일조량이 많은 경우

4. 모델링

데이터 나누기




4. 모델링

Oversampling


SMOTE

낮은 비율로 존재하는 클래스의 데이터를
최근접 이웃(k-NN) 알고리즘을 활용하여 새롭게 생성하는 방법




4. 모델링

Oversampling



< SMOTE 전 train data >



< SMOTE 후 train data >

4. 모델링

① 로지스틱 회귀 모델

Coefficient를 이용한 Feature Importance

cluster1	2.220334
발생장소_시군구_춘천	2.002327
발생장소_시군구_인제	1.553531
발생장소_시군구_강릉	1.394524

⋮

발생장소_시군구_양구	-1.345941
발생장소_시군구_평창	-1.644228
발생장소_시군구_횡성	-1.756966
pc2	-2.305664

cluster 변수 포함 O

발생장소_시군구_춘천	1.695049
발생장소_시군구_인제	1.180490
발생장소_시군구_강릉	1.132051
발생장소_시군구_삼척	0.596495



⋮

발생장소_시군구_횡성	-1.238265
month	-1.260825
pc1	-2.118685
pc2	-2.382718

cluster 변수 포함 X

4. 모델링

② LGBM



4. 모델링

② LGBM

```
pc2
v
pc3
v
pc4
v
pc1
v
month
v
발생장소_시군구_춘천
v
발생장소_시군구_삼척
```


```
pc2
v
hour
v
pc1
v
pc4
v
pc3
v
발생장소_시군구_춘천
```

4. 모델링

③ Randomforest


< Grid search를 통해 최적의 하이퍼 파라미터 설정 >

max_depth : 8
min_samples_leaf : 6
min_samples_split : 6
n_estimators : 14



cluster 변수 포함 0

max_depth : 10
min_samples_leaf : 6
min_samples_split : 18
n_estimators : 18



cluster 변수 포함 X

4. 모델링

③ Randomforest

< 변수 중요도 >

pc2
v
month
v
cluster1
v
발생장소_시군구_춘천
v
발생장소_시군구_삼척

pc2
v
발생장소_시군구_강릉
v
month
v
hour
v
pc1

4. 모델링

④ soft voting

Classifier 1

로지스틱 회귀

Classifier 2

LGBM

Classifier 3

Randomforest

4. 모델링

모델 평가 지표 : F1-score

	로지스틱회귀	LGBM	Randomforest	soft voting
Accuracy	0.86	0.94	0.97	0.94
Precision	0.14	0.11	0.25	0.27
Recall	1.00	0.20	0.20	0.80
F1-score	0.25	0.14	0.22	0.40

< cluster 변수 포함 X >

	로지스틱회귀	LGBM	Randomforest	soft voting
Accuracy	0.90	0.93	0.97	0.94
Precision	0.16	0.08	0.33	0.25
Recall	0.80	0.20	0.20	0.80
F1-score	0.27	0.11	0.25	0.38

< cluster 변수 포함 O >

5. 결론

모델 선정

< 대형 산불 예측 >

cluster 변수 0

cluster 변수 X

로지스틱 회귀

LGBM

Randomforest

soft voting

5. 결론

기대효과

실시간 기상 정보를 활용해 산불 위험 기간 예측
산불 감시 & 초기 대응 고도화

보완점

결측치 처리
모델 성능 - 기상정보만 이용하는 것은 한계
종합적 분석 필요 - 산림 및 소방 정보 / 장기적인 기상 데이터

감사합니다